

stella长文本编码模型



infgrad
再发水文就自戕

已关注

回旋托马斯x、刘聪NLP 等 103 人赞同了该文章

最近更新：

开源stella-base-zh-v2和stella-large-zh-v2, 效果更好且使用简单，不需要任何前缀文本。

[infgrad/stella-base-zh-v2 · Hugging Face](#)

Overall											
Overall MTEB Chinese leaderboard (CMTEB) @ CN											
Rank	Model	Model Size (GB)	Embedding Dimensions	Sequence Length	Average (35 datasets)	Classification Average (9 datasets)	Clustering Average (4 datasets)	Pair Classification Average (2 datasets)	Resranking Average (4 datasets)	Retrieval Average (8 datasets)	STS Average (8 datasets)
1	stella-large-zh-v2	0.65	1024	1024	65.13	69.05	49.16	82.68	66.41	70.14	58.66
2	stella-large-zh	0.65	1024	1024	64.54	67.62	48.65	79.72	65.98	71.02	58.3
3	openai-gpt3.5-turbo	1.3	1024	512	64.53	69.13	48.99	81.6	65.84	70.46	56.25
4	stella-base-zh-v2	0.21	768	1024	64.36	65.29	49.4	79.96	66.1	70.22	56.92
5	stella-base-zh	0.21	768	1024	64.16	67.77	48.7	76.89	66.95	71.07	56.54

1 简介

本文主要介绍下本人最近的一个开源工作：stella系列模型，目前有两个版本：base 和 large，2个版本的模型均支持1024的输入长度。2023-09-14，2个模型在CMTEB中排名第一和第二：

Overall											
Overall MTEB Chinese leaderboard (CMTEB) @ CN											
Rank	Model	Model Size (GB)	Embedding Dimensions	Sequence Length	Average (35 datasets)	Classification Average (9 datasets)	Clustering Average (4 datasets)	Pair Classification Average (2 datasets)	Resranking Average (4 datasets)	Retrieval Average (8 datasets)	STS Average (8 datasets)
1	stella-large-zh	0.65	1024	1024	64.54	67.62	48.65	79.72	65.98	71.02	58.3
2	stella-base-zh	0.21	768	1024	64.16	67.77	48.7	76.89	66.95	71.07	56.54
3	microl-lm-zh	0.65	1024	512	64.11	67.83	47.94	76.38	65.98	70.93	58.82
4	openai-gpt3.5-turbo	1.3	1024	512	63.96	68.32	48.39	79.94	65.11	71.52	54.98
5	microl-lm-base-zh	0.2	768	512	63.66	66.98	47.12	76.61	66.68	71.2	55.9
6	openai-gpt3.5-turbo-instruct	1.3	1024	512	63.4	68.58	50.01	76.77	64.9	70.54	53
7	openai-gpt3.5-turbo	0.41	768	512	62.8	67.07	47.64	77.5	64.91	69.53	54.12
8	openai-gpt3.5-turbo	2.24	1024	514	58.84	67.34	48.23	69.59	56	63.66	48.44
9	openai-gpt3.5-turbo	0.1	512	512	58.28	62.64	45.09	79.35	61.48	63.07	49.45
10	openai-gpt3.5-turbo	0.41	768	512	57.79	67.52	47.68	63.99	59.34	66.4	56.4
11	openai-gpt3.5-turbo	0.41	768	512	57.66	68.2	48.08	64.3	59.64	64.76	58.42

CMTEB排名情况

MTEB Leaderboard - a Hugging Face Space by mteb
huggingface.co/spaces/mteb/leaderboard



训练代码和复现结果的代码如下：

[github.com/SmartLi8/stella](#)



2 基本思路

本人在工作中发现一些场景需要检索的文本块长度超过了512，但是现在的主流开源模型只能处理小于512长度文本，所以本人希望能否在现有模型的基础上把长度扩展到1024甚至更多。事实上512能满足很多需求了，1024则更让人感到可靠。

3 关键问题

基于上边的关键思路，不可避免的要解决三个关键问题：

3.1 如何让模型支持大于512的长度？

本人思考了很多种方法，但是最后选择了最简单的方法，当然在我看来也是最有效的方法（起码在有训练数据的情况下是最有效的），即直接扩充模型原来最大长度，相当于是把position_embedding有(512,768)的shape变为(1024,768)，那么下面的问题就是如何初始化新的512-1024的position embedding了，最终采用了苏神的层次分解位置编码进行初始化。

3.2 如何构造长度大于512的训练数据？

1) 开源数据

首先自然的就会想到开源数据集中长度大于512的数据，但是这些数据的关键信息都集中在了文本块的前半部分，模型只需要重点专注前半部分就可以判断是否匹配，根本不需要看后半部分。

这里举个例子说明这个问题：

query: 小明在哪上大学？

passage: 小明在北京读大学，今年20岁了，学的是计算机专业.....

可以发现不关这个passage有多长，模型只需要重点编码前面十几个字就行。

不幸的是此类数据在开源长数据中占比非常高，若直接拿这些数据训练，虽然长度是大于了512，但是训练出的模型却会走捷径，只关注靠前部分的文字，实际提升非常有限！

既然发现了问题，那么解决方案也非常简单：对于开源数据中的长数据，将其切分成句子，然后依次和query计算集合相似度，相似度最高的句子如果处于passage后半段那么就纳入训练数据，否则就以一定的比例舍弃。

2) LLM合成数据

现在LLM的能力已经非常强大，所以还会考虑找一些长度大于512的无监督文本块，让LLM来生成相关query。其中无监督文本块取自wudao语料库开源的200GB，网上可以自行下载。LLM使用了HFL的Chinese-Alpaca2-13B。具体构造方法为：抽取文本块后面的几个句子，然后模型生成对应的query。prompt比较简单，就不分享了。重点在于要让模型生成文本块后面的几个句子，这样在训练时才会逼着模型学习对文本块后面的文本进行编码

3.3 如何确保训练模型时不会有灾难性遗忘

我们希望在训练模型时，不要让模型遗忘掉原有的知识。stella模型是在piccolo基础上训练的，piccolo本身就拥有极强的文本编码能力。

经过反复实验发现，向量模型的灾难性遗忘问题极其严重，学了新的，基本就把旧的忘了一大半。为了解决这个问题，主要采用了2个策略：

1) Replay，即在训练数据中混合模型原有的训练数据和已有文本匹配数据

loss非常简单，就是新旧模型参数的mse乘以权重。

Train data:

2) 在通用语料库上使用LLM构造一批(question, paragraph)和(sentence, paragraph)数据

CMTEB测试数据不能准确的评估长文本编码能力:

2) 即便大于512, 对于检索而言也只需要前512的文本内容

- CMRC2018, 通用百科
- CAIL, 法律阅读理解
- DRCD, 繁体百科, 已转简体
- Military, 军工问答
- Squad, 英文阅读理解, 已转中文
- Multifieldqa_zh, 清华的大模型长文本理解能力评测数据

Loss function:

- 这样做有2个好处：1) 缓解了类不平衡问题，每次都从不同数据中采样一个batch训练。2) 避免了loss尺度不一致的问题，因为是单独计算互不影响。至于相加会不会更好，本人没做实验也不敢乱说。

CMTEB榜单的结果大家已经可以看到了，个人认为是站在维护榜单初衷的初衷是在CMTEB榜单效果会有所下降，毕竟自己只拿

反而有了提升，因此推测可能是长文本也能反过来促进整体的编码能力吧。

长文本编码能力测试

评测指标为Recall@5, 结果如下：

Dataset	piccolo-base-zh	piccolo-large-zh	bge-base-zh	bge-large-zh	stella-base-zh	stella-large-zh
CMRC2018	94.34	93.82	91.56	93.12	96.08	95.56
CAIL	28.04	33.64	31.22	33.94	34.62	37.18
DRCDD	78.25	77.9	78.34	80.26	86.14	84.58
Military	76.61	73.06	75.65	75.81	83.71	80.48
Squad	91.21	86.61	87.87	90.38	93.31	91.21
Multifieldqa_zh	81.41	83.92	83.92	83.42	79.9	80.4
Average	74.98	74.83	74.76	76.15	78.96	78.14

结果复现

复现CMTEB结果的脚本和训练模型的脚本如下：

github.com/SmartLi8/stella

6 总结

实际使用时建议多试几个模型，在有些数据集上可能排名靠后的模型效果反而好。

本工作还存在以下问题：

评测的稳定性： 评测过程中发现Clustering任务会和官方的结果不一致，大约有±0.0x的小差距，基本上可以忽略不计，不影响评测结论。
但是不完全一样还是比较难理解的，本人试了bge和piccolo系列的模型都存在这个问题，个人猜测可能和使用的库、batch_size等环境有关。

更高质量的长文本训练和测试数据： 训练数据多是用13b模型构造的，肯定会存在噪声。测试数据基本都是从mrc数据整理来的，所以问题都是factoid类型，不符合真实分布。

OOD的性能： 虽然近期出现了很多向量编码模型，但是对于不是那么通用的domain，这一众模型包括stella、openai和cohere，它们的效果均比不上BM25。

7 Reference

- scidb.cn/en/detail?...
- github.com/wangyuxinwhy...
- github.com/CLUEbenchmark...
- arxiv.org/abs/1612.0079...
- kexue.fm/archives/8847
- huggingface.co/sensenov...
- kexue.fm/archives/7947
- github.com/FlagOpen/Fla...
- github.com/THUDM/LongBe...

编辑于 2023-10-13 13:10 · IP 属地江苏

向量 检索



理性发言，友善互动

- 42 条评论

默认 最新
- takoony**

...

楼主，训练数据集可以开放不😄

2023-10-26 · 广东

回复 喜欢 3
- momo**

...

请问一下“评测过程中发现Clustering任务会和官方的结果不一致”这个clustering任务指的是啥？

08-01 · 欧洲地区

回复 喜欢
- HeroPeco**

...

感谢楼主无私的经验分享👍👍👍

想请教您一个问题，2) LLM合成数据中提到的“抽取文本块后面的几个句子，然后模型生成对应的query”，是指一个在一个512长度的文本中抽取后面几个句子，让LLM对后面几个句子进行总结或者提问来生成query吗？如果可以的话能看看您写的Prompt吗🐱

05-16 · 广东

回复 喜欢
- 萧忆情**

...

请问下如何在论文中引用工作

05-03 · 重庆

回复 喜欢
- infgrad** 作者

...

直接知乎链接就可以的，或者hf的链接

05-04 · 江苏

回复 喜欢
- lsf10**

...

请问为啥第一版需要前缀文本呀，在第二版中是否仅仅是直接将前缀文本删除训练得到的模型？

03-07 · 上海

回复 喜欢
- 夜雨飘零**

...

请问训练可以添加负样本不？

2023-12-11 · 广东

回复 喜欢
- 夜雨飘零** ▸ infgrad

...

好的，谢谢回答，可以顺便回答这个问题吗：[github.com/SmartLi8/ste...](https://github.com/SmartLi8/stella)

2023-12-12 · 广东

回复 喜欢
- infgrad** 作者 ▸ 夜雨飘零

...

回了

2023-12-12 · 江苏

回复 喜欢
- 展开其他 1 条回复
- Pacino**

...

请问蹲神，在长文本评测时，使用recall@5 指标评测模型时，召回的数据库是所有的文本合集吗？

2023-12-05 · 上海

回复 喜欢
- infgrad** 作者

...

你指的是具体什么评测？正常评测时数据库肯定要用所有文本，这才是recall的含义吧

2023-12-05 · 江苏

回复 喜欢
- jason**

...

楼主，代码实现好像有点问题，ewc loss全是0

2023-11-29 · 浙江

回复 喜欢



joyoung

...

请问大佬，微调数据集长度在512以下，这样微调的时候是不是不必打开ewc loss了呢

2023-11-10 · 北京

回复 喜欢



takoony

...

在公司的行业内数据测试，其效果和BGE模型差不多，有得好些，有得差些，stellar 阈值分布更合理些

2023-11-06 · 广东

回复 喜欢

点击查看全部评论 >



理性发言，友善互动

推荐阅读




Stellaris开发日志#137 | 12/20
更新、假期以及未来计划！

猫猫猫猫堂 发表于牧游社



Stellaris开发日志#125 | 9/13
银河市场

猫猫猫猫堂



Stellaris开发日志#124 | 9/13
游商舰队

猫猫猫猫堂